Herramientas de cómputo cognitivo para convertir contenido visual y audiovisual en datos estructurados

Aarón Hernández Jiménez · A01642529 · Visualización de datos (TC4057, Gpo 10) · Actividad 4 · 10 de octubre de 2026

El cómputo cognitivo combina visión por computadora, reconocimiento de voz y procesamiento de lenguaje natural para convertir imágenes, audio y video en datos estructurados: la ubicación de un rostro, una edad estimada, la transcripción de lo que alguien dijo o el sentimiento de una frase, cada dato con su nivel de confianza y su marca de tiempo. Este informe analiza tres herramientas con modelos de acceso distintos: un servicio en la nube de pago por uso (Amazon Rekognition), una plataforma audiovisual multimodal (Azure AI Video Indexer) y una biblioteca de código abierto (DeepFace).

1. Amazon Rekognition

Proveedor. Amazon Web Services (AWS). Se usa mediante una API en la nube, la consola web o los SDK para lenguajes como Python y Java.

Funcionalidades. Analiza imágenes y video. Detecta rostros, objetos, escenas, texto y contenido inapropiado; compara dos rostros, busca un rostro en colecciones previamente indexadas, reconoce celebridades y verifica que quien está frente a la cámara sea una persona real (Face Liveness).

Datos que extrae. Por cada rostro devuelve un objeto JSON con su ubicación, pose y calidad, un rango de edad estimado, una predicción binaria de género y la confianza de ocho emociones (feliz, triste, enojado, confundido, disgustado, sorprendido, calmado y miedo), además de atributos como sonrisa o lentes. AWS recomienda un umbral de confianza de 99 % para usos sensibles y aclara que el género y la emoción describen la apariencia física, no la identidad de género ni el estado emocional real de la persona (Amazon Web Services [AWS], s. f.-c).

Ejemplos de uso. Marinus Analytics integró la búsqueda facial de Rekognition en Traffic Jam, una herramienta para investigar la trata de personas que compara fotografías de víctimas con millones de anuncios en segundos. Según AWS, ayudó a localizar a una adolescente desaparecida y a identificar a 20 víctimas de un mismo tratante en tres meses, en lugar de los dos años habituales (Larsen, 2018). AWS también lo propone para estimar de forma anónima la demografía del público en tiendas o eventos. El costo inicial ronda USD 0.001 por imagen, con un nivel gratuito de 1,000 imágenes al mes (AWS, s. f.-b); desde el 30 de abril de 2026, el análisis de video en streaming y el análisis masivo de imágenes ya no se ofrecen a clientes nuevos (AWS, s. f.-a).

2. Azure AI Video Indexer

Proveedor. Microsoft, como parte de Azure AI. Funciona como portal web sin código, como API y como extensión de Azure Arc para procesar el video en las instalaciones del cliente.

Funcionalidades. Ejecuta varios modelos de audio y video sobre el mismo archivo y une sus resultados en una sola línea de tiempo. En el video detecta y agrupa rostros, identifica celebridades o personas entrenadas por la cuenta, lee texto (OCR), reconoce objetos y acciones, segmenta escenas y detecta personas y su ropa. En el audio transcribe más de 50 idiomas, traduce, genera subtítulos, distingue hasta 16 hablantes y detecta efectos como sirenas, aplausos, disparos o risas (Microsoft, 2026).

Datos que extrae. Un índice JSON con marcas de tiempo: quién aparece y cuándo, qué dijo cada hablante, palabras clave, entidades (marcas, lugares y personas), temas, sentimiento positivo, negativo o neutral y emociones detectadas en la transcripción (alegría, tristeza, enojo y miedo).

Ejemplos de uso. Accenture produce unos 140 eventos de transmisión al mes y acumulaba cerca de un petabyte de video que no podía buscar. Con Video Indexer creó Video IQ, que genera transcripciones con tiempos, identifica a los oradores con un modelo facial propio (con su consentimiento) y resume cada video; hoy procesa de 200 a 300 clips por semana (Microsoft, 2025). Microsoft cobra según la duración del archivo analizado y ofrece una cuenta de prueba. La identificación facial y de celebridades requiere solicitar acceso limitado, y desde 2023 Microsoft retiró de su servicio Face la inferencia de emociones, género y edad a partir del rostro (Bird, 2022).

3. DeepFace

Proveedor. Biblioteca de Python de código abierto (licencia MIT) creada por Sefik Ilkin Serengil y publicada en GitHub.

Funcionalidades. Reconoce y verifica rostros y analiza sus atributos. Integra modelos de reconocimiento conocidos (VGG-Face, FaceNet y ArcFace, entre otros) y varios detectores de rostros (OpenCV, RetinaFace, MTCNN y YOLO). Se instala con pip y una sola función, `DeepFace.analyze`, devuelve los atributos de cada rostro. Se ejecuta en la computadora del usuario, sin enviar las imágenes a terceros.

Datos que extrae. Edad estimada en años, género, la emoción dominante con la probabilidad de siete emociones (enojo, miedo, neutral, tristeza, disgusto, alegría y sorpresa) y una de seis categorías de origen étnico. El autor reporta un error medio de ±4.65 años en la edad y 97.44 % de exactitud en el género (Serengil, 2026).

Ejemplos de uso. Biswas et al. (2025) analizaron 51,680 videos políticos de TikTok de la elección presidencial de 2024 en EE. UU. y usaron DeepFace para identificar la edad y el género de los oradores. Al validar a mano una muestra de 50 videos, DeepFace acertó en 84.4 % de los casos en género, 78 % en edad y 74 % en la emoción dominante: suficiente para describir tendencias agregadas, pero por debajo de las cifras de laboratorio.

4. Comparación

La tabla 1 resume las diferencias. La precisión se presenta con la evidencia disponible, porque ningún proveedor publica una cifra única que permita comparar las tres herramientas en igualdad de condiciones.

Tabla 1. *Comparación de las tres herramientas*

Criterio	Amazon Rekognition	Azure AI Video Indexer	DeepFace
Contenido de entrada	Imágenes y video.	Video y audio.	Imágenes y fotogramas de video.
Datos estructurados	Rostros, rango de edad, género, 8 emociones, identidad en colecciones, objetos y texto.	Transcripción, hablantes, rostros, OCR, temas, entidades, sentimiento y emoción en el texto.	Edad, género, 7 emociones, origen étnico y verificación de identidad.
Precisión (evidencia)	AWS no publica una cifra global. Una auditoría midió 8.66 % de error al clasificar género y 31.37 % en mujeres de piel oscura (Raji y Buolamwini, 2019).	Microsoft no publica una cifra única; la calidad depende de cada modelo y de las condiciones del audio (ruido, acentos e idioma).	Según el autor, ±4.65 años en edad y 97.44 % en género; en videos reales, 84.4 % en género y 74 % en emoción (Biswas et al., 2025).
Facilidad de uso	Alta: consola y API bien documentadas, pero requiere cuenta de AWS y algo de programación.	Muy alta: el portal web no requiere código y la API permite automatizar.	Media: requiere Python y pocas líneas de código; el usuario administra modelos y equipo.
Costo y acceso	Pago por uso (≈ USD 0.001 por imagen) y nivel gratuito.	Cuenta de prueba y cobro por duración del archivo; funciones faciales con acceso limitado.	Gratuito; solo el costo del equipo propio.
Aplicaciones potenciales	Seguridad (verificación de identidad, investigaciones), marketing (demografía anónima) y moderación de contenido.	Medios y archivos (búsqueda), accesibilidad (subtítulos), marketing (publicidad contextual) y capacitación.	Investigación y prototipos; en salud, solo de forma exploratoria y con consentimiento.

5. Reflexión: ventajas y limitaciones

Ventajas. Estas herramientas convierten horas de video o millones de imágenes en tablas que se pueden consultar, filtrar y graficar en minutos, una tarea que antes requería etiquetado manual. Para la visualización de datos esto abre fuentes nuevas, como el tiempo en pantalla de cada persona, el sentimiento a lo largo de un discurso o la composición demográfica de una muestra de videos. También mejoran la accesibilidad con subtítulos y traducciones automáticas, y reducen costos de operación, como en el caso de Accenture.

Limitaciones. La primera es científica: una revisión de más de 1,000 estudios concluyó que los movimientos faciales no permiten inferir de forma confiable la emoción que siente una persona, porque una misma expresión cambia de significado según el contexto, la persona y la cultura (Barrett et al., 2019). Por eso Microsoft retiró la inferencia de emociones (Bird, 2022) y AWS advierte que sus predicciones solo describen apariencia. La segunda es el sesgo: el error de Rekognition al clasificar género fue de 31.37 % en mujeres de piel oscura y prácticamente nulo en hombres de piel clara (Raji y Buolamwini, 2019); además, el género binario y las categorías étnicas fijas simplifican identidades complejas. La tercera es legal: en México, la Ley Federal de Protección de Datos Personales en Posesión de los Particulares (2025) considera sensibles los datos que

pueden revelar el origen racial o étnico o el estado de salud, y exige consentimiento expreso y por escrito para tratarlos (arts. 2 y 8), justo el tipo de dato que estima DeepFace; en la Unión Europea, desde febrero de 2025 está prohibido inferir emociones en el trabajo y en centros educativos (Reglamento [UE] 2024/1689, art. 5). Por último, depender de un proveedor implica riesgo, porque Microsoft y AWS han retirado funciones en los últimos años; el código abierto evita ese riesgo, pero traslada al usuario la responsabilidad de validar los resultados y proteger los datos.

En conclusión, estas tecnologías son más confiables para medir tendencias agregadas y anónimas, validadas con una muestra revisada a mano como hicieron Biswas et al. (2025), que para tomar decisiones sobre una persona concreta.

Referencias

Amazon Web Services. (s. f.-a). *Amazon Rekognition feature availability changes*. Recuperado el 10 de octubre de 2026 de https://docs.aws.amazon.com/rekognition/latest/dg/rekognition-availability-changes.html

Amazon Web Services. (s. f.-b). *Amazon Rekognition pricing*. Recuperado el 10 de octubre de 2026 de https://aws.amazon.com/rekognition/pricing/

Amazon Web Services. (s. f.-c). *Guidelines on face attributes*. Recuperado el 10 de octubre de 2026 de https://docs.aws.amazon.com/rekognition/latest/dg/guidance-face-attributes.html

Barrett, L. F., Adolphs, R., Marsella, S., Martinez, A. M. y Pollak, S. D. (2019). Emotional expressions reconsidered: Challenges to inferring emotion from human facial movements. *Psychological Science in the Public Interest, 20*(1), 1–68. https://doi.org/10.1177/1529100619832930

Bird, S. (2022, 21 de junio). Responsible AI investments and safeguards for facial recognition. *Microsoft Azure Blog*. https://azure.microsoft.com/en-us/blog/responsible-ai-investments-and-safeguards-for-facial-recognition/

Biswas, A., Javadian Sabet, A. y Lin, Y.-R. (2025). Toxic politics and TikTok engagement in the 2024 U.S. election. *Harvard Kennedy School (HKS) Misinformation Review*. https://doi.org/10.37016/mr-2020-181

Larsen, K. (2018, 9 de agosto). Marinus Analytics fights human trafficking using Amazon Rekognition. *AWS Machine Learning Blog*. https://aws.amazon.com/blogs/machine-learning/marinus-analytics-fights-human-trafficking-using-amazon-rekognition/

Ley Federal de Protección de Datos Personales en Posesión de los Particulares. Diario Oficial de la Federación, 20 de marzo de 2025 (México). https://www.diputados.gob.mx/LeyesBiblio/pdf/LFPDPPP.pdf

Microsoft. (2025, 17 de noviembre). *Accenture transforms video content management with Azure AI Video Indexer*. https://www.microsoft.com/en/customers/story/25711-accenture-azure-ai-video-indexer

Microsoft. (2026). *What is Azure AI Video Indexer?* Microsoft Learn. https://learn.microsoft.com/en-us/azure/azure-video-indexer/video-indexer-overview

Raji, I. D. y Buolamwini, J. (2019). Actionable auditing: Investigating the impact of publicly naming biased performance results of commercial AI products. En *Proceedings of the 2019 AAAI/ACM Conference on AI, Ethics, and Society* (pp. 429–435). Association for Computing Machinery. https://doi.org/10.1145/3306618.3314244

Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo, de 13 de junio de 2024, por el que se establecen normas armonizadas en materia de inteligencia artificial. Diario Oficial de la Unión Europea, L, 12 de julio de 2024. https://eur-lex.europa.eu/eli/reg/2024/1689/oj

Serengil, S. I. (2026). *DeepFace: A lightweight face recognition and facial attribute analysis framework for Python* [Software]. GitHub. https://github.com/serengil/deepface

Declaración de uso de IA

Anthropic. (2026). *Claude (Opus 5.5)* [Modelo de lenguaje grande], utilizado para la búsqueda y verificación de fuentes, apoyo en la redacción y corrección ortográfica del informe y el formato de la documentación. https://claude.ai/